Programmation sur Processeur Graphique

—

Partie 2 : Allocation des données et exécution d'un kernel

Pierre-Emmanuel Hladik
pierre-emmanuel.hladik@ec-nantes.fr

24 février 2025

Plan

1. Introduction à la programmation parallèle
2. Allocation des données et exécution d'un kernel
3. Kernel à plusieurs dimensions

Structure d'un programme C en CUDA

host et *device*

- *host* = CPU
- *device* = GPU

Principe d'exécution : fonction et kernel

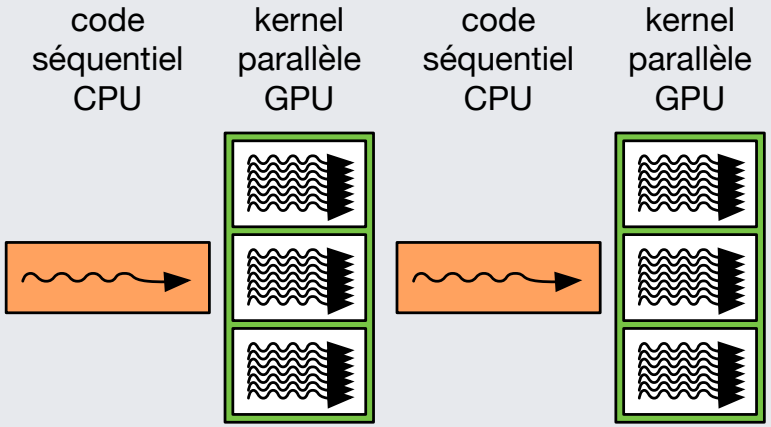

Exemple avec une addition vectorielle

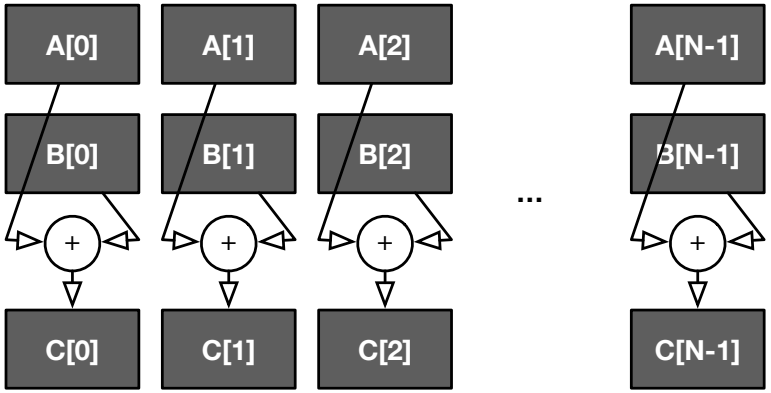


```
// Compute vector sum C = A + B
void vecAdd (float *h_A , float *h_B , float * h_C , int n)
{
  int i;
  for (i = 0; i<n; i++) {
    h_C [i] = h_A [i] + h_B [i];
  }
}

int main()
{
  // Memory allocation for for h_A , h_B , and h_C
  // I/O to read  h_A and h_B , N elements
  ...
  vecAdd (h_A , h_B , h_C , N);
}
```

Cas pratique : le collectif vu comme un GPU

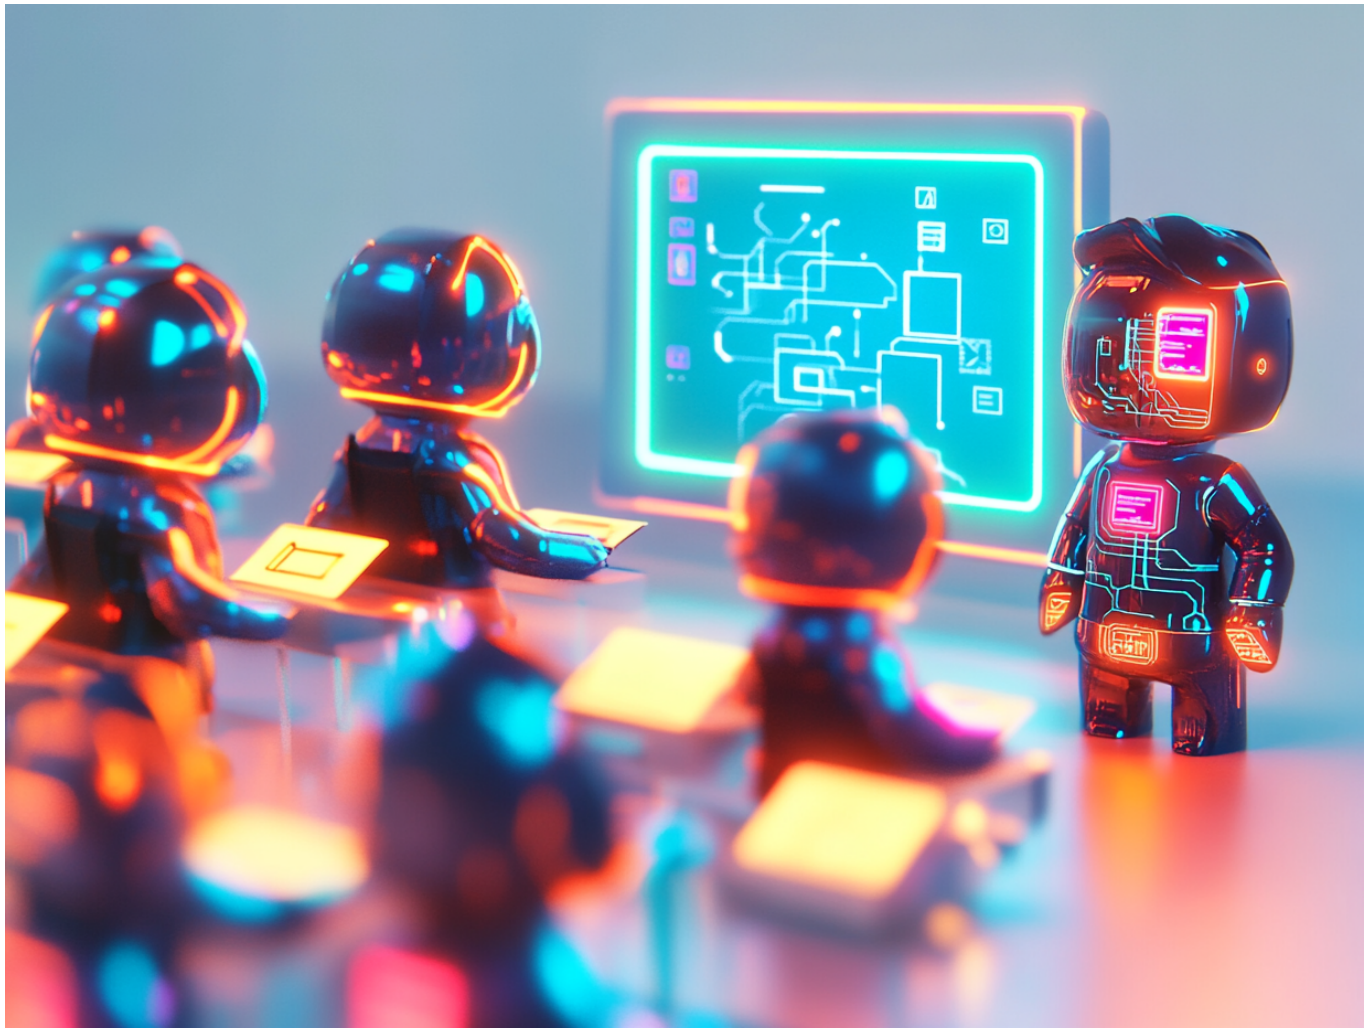

id groupe + id thread => quel code écrire ?

Structure basique d'un code CUDA

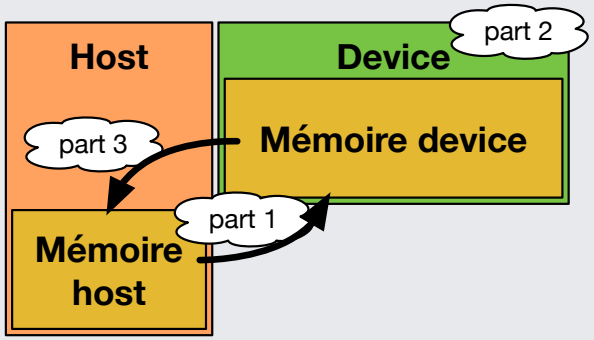


```
#include <cuda.h>
void vecAdd(float *h_A, float *h_B, float *h_C, int n)
{
    int size = n* sizeof(float);
    float *d_A, *d_B, *d_C;
    // Part 1
    // Allocate device memory for A, B, and C
    // copy A and B to device memory

    // Part 2
    // Kernel launch code - the device performs the actual vector addition

    // Part 3
    // copy C from the device memory
    // Free device vectors
}
```

Allocation mémoire : cudaMalloc

```
#include <cuda.h>
void vecAdd(float *h_A, float *h_B, float *h_C, int n)
{
   int size = n* sizeof(float);
   float *d_A, *d_B, *d_C;
   // Allocate device memory for A, B, and C
   cudaMalloc((void **) &d_A, size);
   cudaMalloc((void **) &d_B, size);
   cudaMalloc((void **) &d_C, size);

   // copy A and B to device memory

   // Part 2
   // Kernel launch code - the device performs the actual vector addition

   // Part 3
   // copy C from the device memory
   // Free device vectors
}
```

Désallocation mémoire : cudaFree

```
#include <cuda.h>
void vecAdd(float *h_A, float *h_B, float *h_C, int n)
{
   int size = n* sizeof(float);
   float *d_A, *d_B, *d_C;
   // Allocate device memory for A, B, and C
   cudaMalloc((void **) &d_A, size);
   cudaMalloc((void **) &d_B, size);
   cudaMalloc((void **) &d_C, size);

   // copy A and B to device memory

   // Part 2
   // Kernel launch code - the device performs the actual vector addition

   // Part 3
   // copy C from the device memory
   // Free device vectors
   cudaFree(d_A); cudaFree(d_B); cudaFree(d_C);
}
```

Copie mémoire : cudaMemcpy

```
#include <cuda.h>
void vecAdd(float *h_A, float *h_B, float *h_C, int n)
{
   int size = n* sizeof(float);
   float *d_A, *d_B, *d_C;
   // Allocate device memory for A, B, and C
   cudaMalloc((void **) &d_A, size);
   cudaMalloc((void **) &d_B, size);
   cudaMalloc((void **) &d_C, size);

   // copy A and B to device memory
   cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
   cudaMemcpy(d_B, h_B, size, cudaMemcpyHostToDevice);

   // Part 2
   // Kernel launch code - the device performs the actual vector addition

   // Part 3
   // copy C from the device memory
   cudaMemcpy(h_C, d_C, size, cudaMemcpyDeviceToHost);
   // Free device vectors
   cudaFree(d_A); cudaFree(d_B); cudaFree(d_C);
}
```

Kernel, grid, block et thread

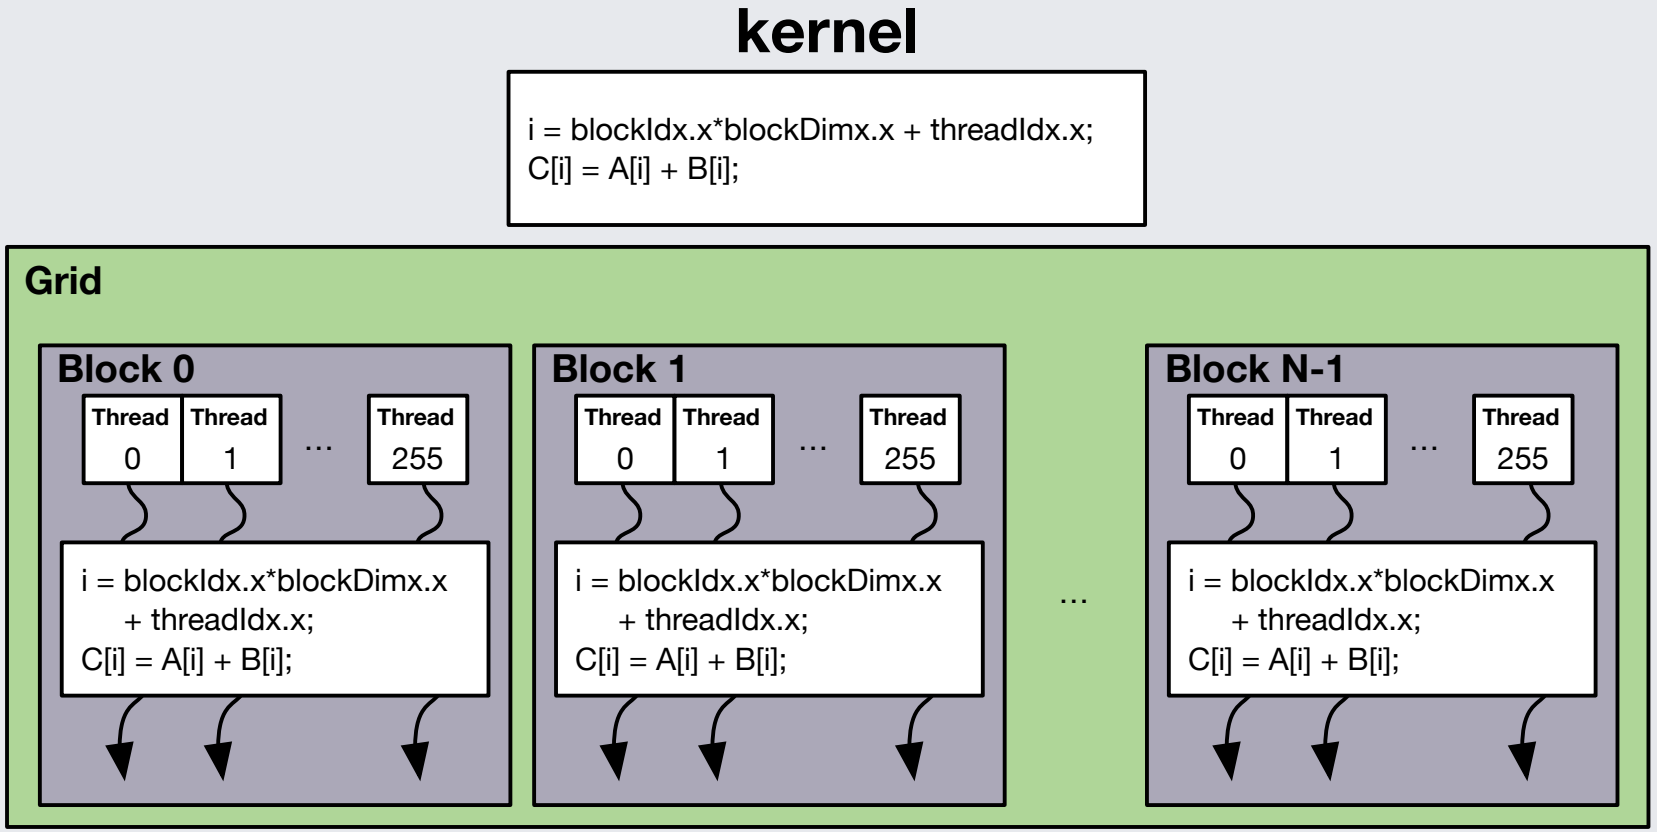

- Les threads d'un block coopèrent via une **shared memory**, **atomic operations** et **barrier synchronization**
- les threads dans des blocs différents ne coopèrent pas

Thread index

- Chaque thread a un index qui peut être utilisé pour manipuler les adresses mémoires et faire des choix d'exécution

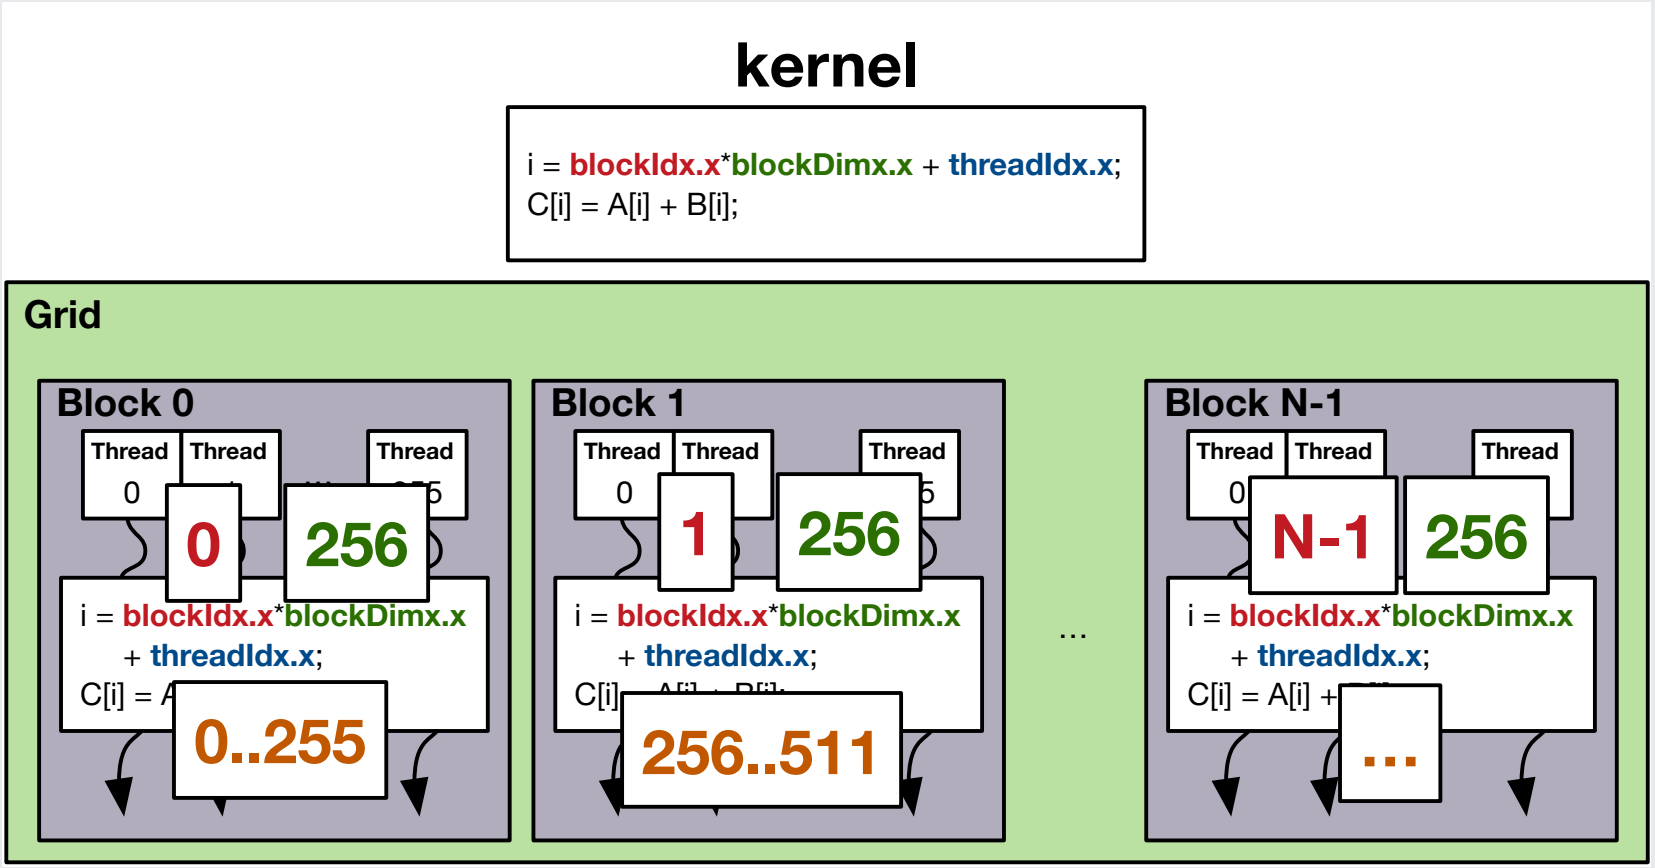

Définition d'un kernel en CUDA

```
// Compute vector sum C = A + B
// Each thread performs one pair-wise addition

__global__
void vecAddKernel(float* A, float* B, float* C, int vectorSize)
{
  int kernelIdx = threadIdx.x + blockDim.x*blockIdx.x;
  if(i < vectorSize)
  {
    C[kernelIdx] = A[kernelIdx] + B[kernelIdx];
  }
}
```

Execution d'un kernel

```
// Compute vector sum C = A + B
// Each thread performs one pair-wise addition

__global__
void vecAddKernel(float* A, float* B, float* C, int vectorSize)
{
  int kernelIdx = threadIdx.x + blockDim.x*blockIdx.x;
  if(kernelIdx < vectorSize)
  {
    C[kernelIdx] = A[kernelIdx] + B[kernelIdx];
  }
}

void vecAdd(float* h_A, float* h_B, float* h_C, int size)
{
  // d_A, d_B, d_C allocations and copies omitted
  // Run ceil((float)n/256.0) blocks of 256 threads each
  int number_of_blocks = ceil((float) size / 256.0);
  int number_of_threads_per_block = 256;
  vecAddKernel<<< number_of_blocks, number_of_threads_per_block >>>(d_A, d_B, d_C, n);
}
```

Thread index

```
__host__
void vecAdd(float* h_A, float* h_B, float* h_C, int n)
{
  int nb_of_blocks = ceil(n/256.0);
  int nb_of_threads_per_block = 256;
  vecAddKernel<<<nb_of_blocks,nb_of_threads_per_block>>>(d_A, d_B, d_C, n);
}
```

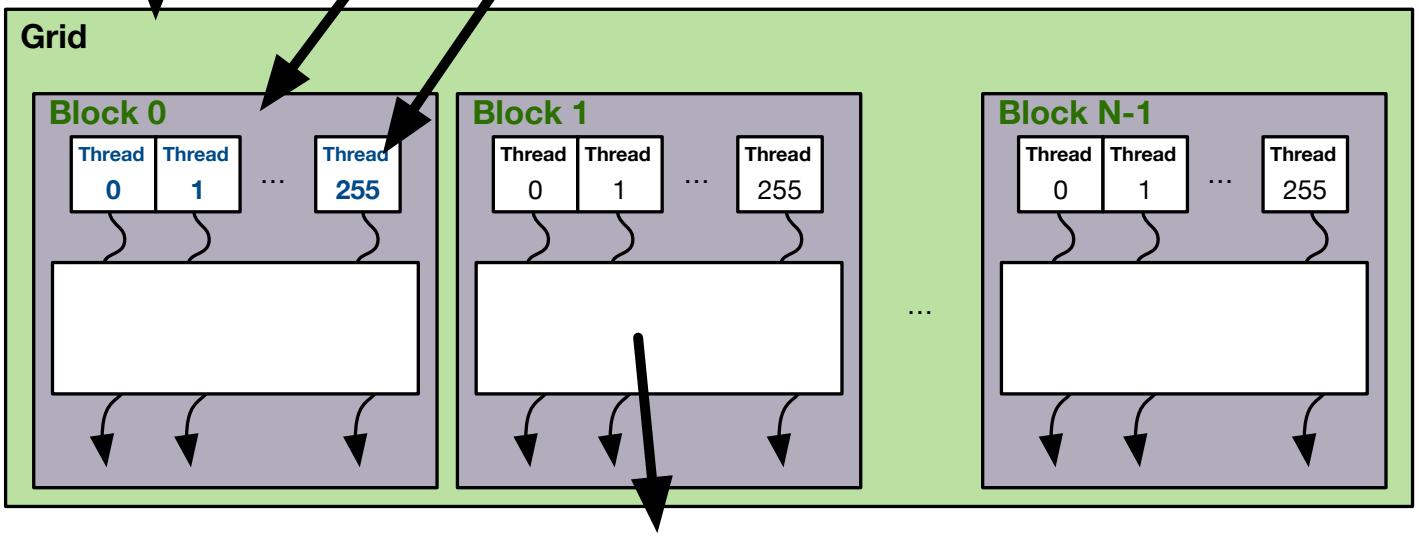


```
__global__
void vecAddKernel(float* A, float* B, float* C, int n)
{
  int i = threadIdx.x + blockDim.x*blockIdx.x;
  if(i<n) C[i] = A[i] + B[i];
}
```

Mots-clef en CUDA-C pour déclarer les fonctions

	exécuté sur	appelé par
`__device__ float DeviceFunc()`	device	device
`__global__ void KernelFunc()`	device	host
`__host__ float HostFunc()`	host	host

- `__global__` définit une fonction kernel
- Une fonction kernel doit retourner un `void` (mais peut prendre ce que l'on veut en argument)
- `__device__` et `__host__` peuvent être utilisés conjointement pour avoir deux versions objet de la même fonction.
- `__host__` est optionnel s'il est utilisé seul

Si on veut bien faire les choses : gestion des erreurs

Toutes les fonctions de l'API CUDA retournent un code d'erreur (de type `cudaError_t`), il peut être utile de tester la valeur pour s'éviter de problème, par exemple :

```
cudaError_t  err = cudaMalloc((void **) &d_A, size);

if (err != cudaSuccess)  {
   printf("%s in %s at line %d\n",   cudaGetErrorString(err), __FILE__,
   __LINE__);
   exit(EXIT_FAILURE);
}
```

Attention l'appel au kernel `<<<...>>>()` n'est pas un appel de fonction et se fait de manière asynchrone. Il faut utiliser `cudaGetLastError()` et surtout `cudaDeviceSynchronize()` pour se synchroniser (voir TD pour plus de détails).

Description : `Blocks until the device has completed all preceding requested tasks. cudaDeviceSynchronize() returns an error if one of the preceding tasks has failed.`

Un peu de pratique avec le TD2

Objectifs

- Allocation mémoire et écriture d'un premier kernel
- Gérer les erreurs
- Se casser les dents sur la gestion de la mémoire structurée