Programmation sur Processeur Graphique

—

Partie 9 : Algorithme parallèle de réduction

Pierre-Emmanuel Hladik
pierre-emmanuel.hladik@ec-nantes.fr

28 février 2025

Qu'est-ce q'un algorithme de réduction ?

Agglomérer un ensemble de valeurs d'entrée en une seule valeur en utilisant une "opération de réduction", exemples :

- Max
- Min
- Somme
- Produit

Algorithme séquentiel en O(N)

1. Initialiser le résultat en tant que valeur d'identité pour l'opération de réduction :
   - La plus petite valeur possible pour le Max
   - Valeur la plus élevée possible pour le Min
   - 0 pour la Somme
   - 1 pour le Produit
2. Itérer sur les valeurs d'entrée l'opération de réduction entre la valeur du résultat et la valeur actuelle

- N opérations de réduction effectuées pour N valeurs d'entrée
- Chaque valeur d'entrée n'est visitée qu'une seule fois – algorithme en O(N)
- Il s'agit d'un algorithme efficace sur le plan du calcul

Stratégie de partionnement et d'aglomération

Une stratégie couramment utilisée pour le traitement de grands ensembles de données d'entrée

- pas d'ordre requis des éléments de traitement dans un ensemble de données
- Diviser l'ensemble de données en plus petits morceaux
- Avoir un thread pour traiter un morceau
- Construire un arbre de réduction pour agglomérer les résultats de chaque morceau

Algo parallèle d'arbre de réduction en log(N) étapes

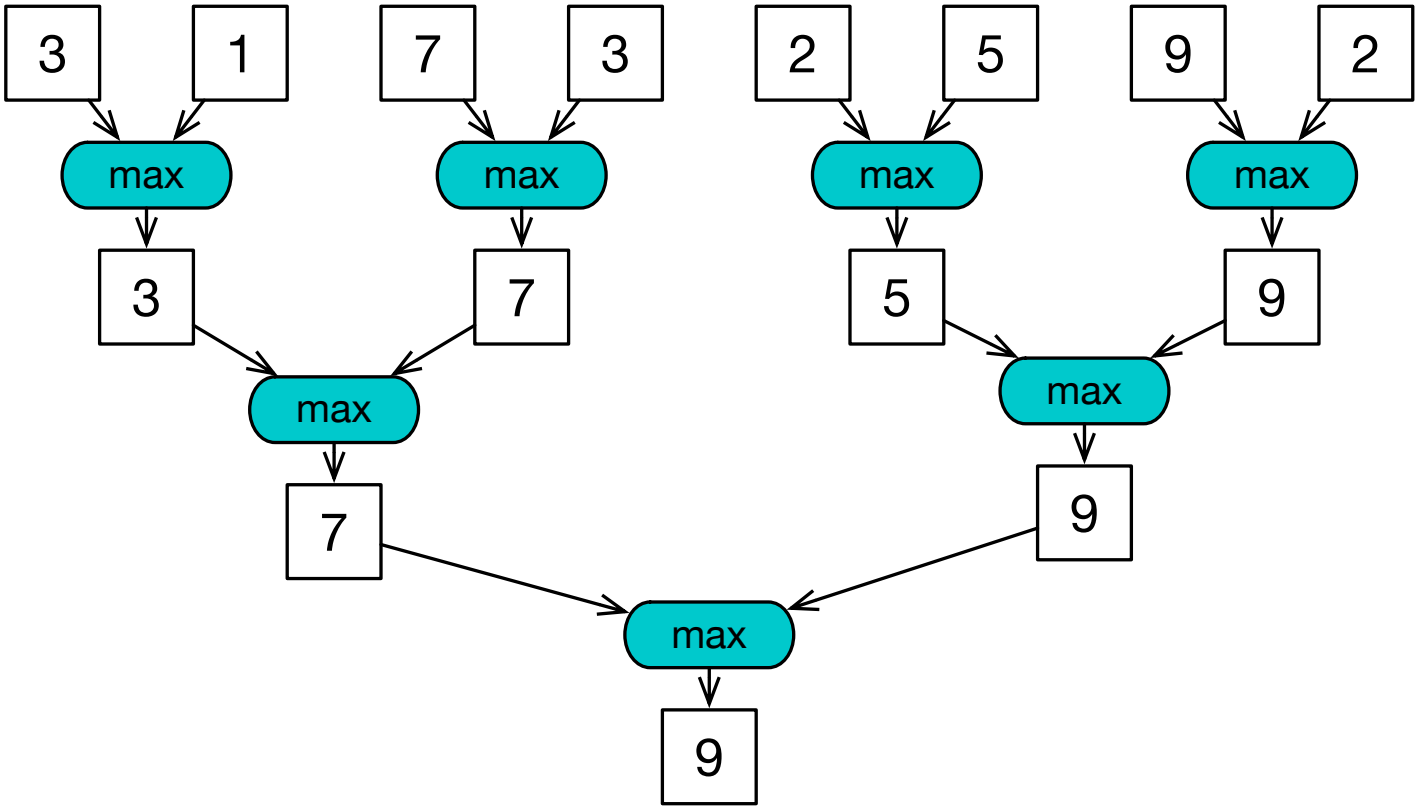

Analyse rapide

Pour n valeurs l'arbre de réduction effectue :

- $(1/2)n + (1/4)n + (1/8)n + ... = (1\text{-}(1/n))n = n\text{-}1$ opérations en log (n) étapes
  - Exemple : le traitement de 1 000 000 de valeurs prend 20 étapes (en supposant que nous disposions de ressources d'exécution suffisantes)
- Parallélisme moyen $(n\text{-}1)/\log(n)$
  - Pour N = 1 000 000, le parallélisme moyen est de 50 000
  - Toutefois, le pic de ressources nécessaires est de 500 000
- C'est un algorithme parallèle performant en terme de travail
  - La quantité de travail effectuée est comparable à celle d'un algorithme séquentiel efficace

Exemple : réduction d'un maximum

Implémentation parallèle

- Chaque thread compare 2 valeurs à chaque étape
- Réduit par 2 le nombre de thread à chaque étape
- Utilise $\log(n)$ étapes pour n éléments et $n/2$ threads

Exemple d'utilisation de la mémoire partagée sur une somme

- Au départ, la mémoire partagée contient le vecteur initial
- Chaque étape rapproche la somme partielle de la somme
- La somme finale sera dans l'élément 0 du vecteur partagée
- Réduit le trafic global de mémoire grâce à la lecture et à l'écriture de valeurs
- La taille maximale des blocs doit être inférieure ou égale à 2048

Exemple : réduction d'une somme (schéma)

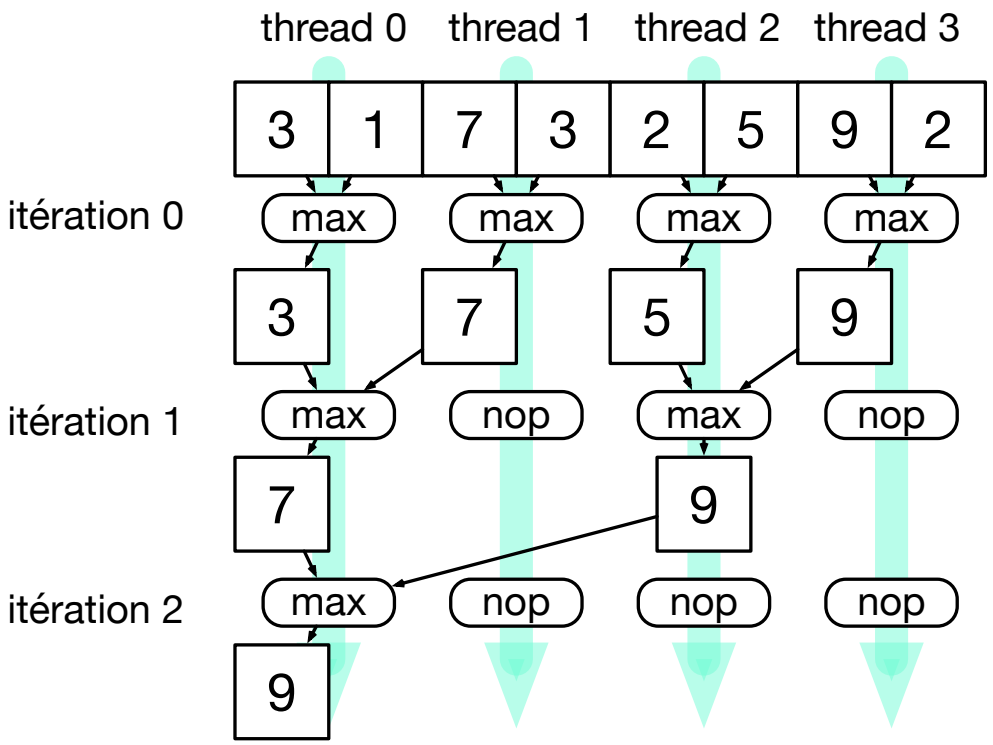

Exemple : implémentation naïve

- Chaque block dispose de 2*BlockDim.x éléments
- Chaque thread charge 2 éléments dans la mémoire partagée

```
__global__
void redux(float* input, float* ouput) {

  __shared__ float max[2*BLOCK_SIZE];

  int tx = threadIdx.x;
  int start = 2 * blockIdx.x * blockDim.x;

  // write data in shared memory
  max[tx] = input[start + tx];
  max[blockDim + tx] = input[start + blockDim.x + tx];

  for (int stride = 1; stride <= blockDim.x;  stride *= 2)
  {
    __syncthreads();
    if (tx % stride == 0)
        max[2 * tx] = ( (max[2 * tx] > max[2 * tx + stride]) ? max[2 * tx] : max[2 * tx + stride]);
  }

  ouput[blockIdx.x] = max[0];

}
```

Commentaires sur l'implémentation naïve (divergence)

A chaque itération, deux chemins de flux de contrôle (**divergence**) seront parcourus séquentiellement pour chaque *warp* :

- Les threads qui effectuent des comparaison et les threads qui n'en effectuent pas
- Les threads qui n'effectuent pas de comparaison "bloquent" des ressources d'exécution

La moitié ou moins des threads seront en cours d'exécution après la première étape

- Tous les threads d'indices impairs sont inactifs après la première étape
- Après la 5e étape, des warps entier dans chaque bloc échouent le test conditionnel (une mauvaise utilisation des ressources mais aucune divergence)
- Cela peut durer un certain temps, jusqu'à 6 étapes supplémentaires (stride = 32, 64, 128, 256, 512, 1024), où chaque warp active n'a qu'un thread "productif".

Toujours regrouper les threads "productifs"

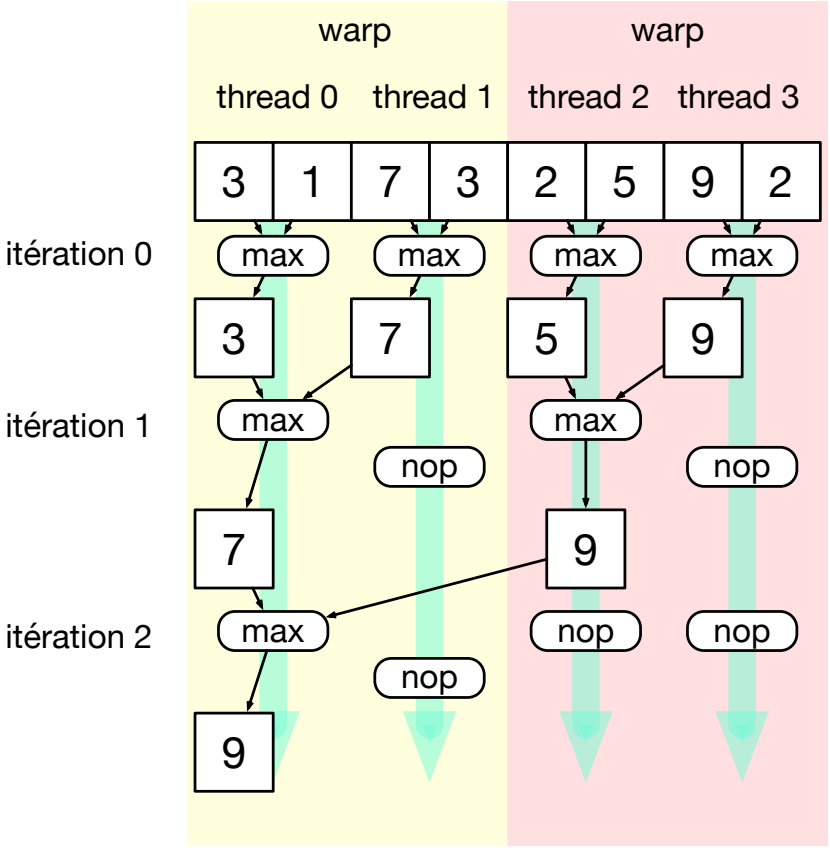

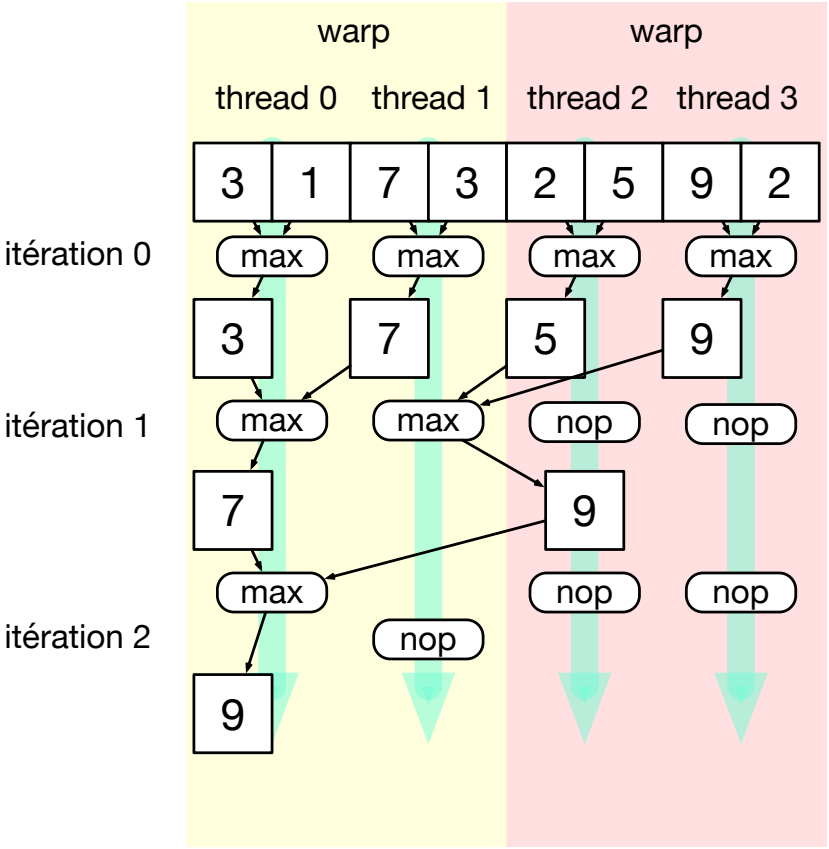

Exemple : implémentation plus efficace

```
__global__
void redux(float* input, float* ouput) {

  __shared__ float max[2*BLOCK_SIZE];

  int tx = threadIdx.x;
  int start = 2 * blockIdx.x * blockDim.x;

  max[t] = input[start + tx];
  max[blockDim + tx] = input[start + blockDim.x + tx];

  for (int stride = blockDim.x; stride > 0; stride /= 2)
  {
    __syncthreads();
    if (tx < stride)
        max[2 * tx] = ( (max[2 * tx] > max[2 * tx + stride]) ? max[2 * tx] : max[2 * tx + stride]);
  }
  ouput[blockIdx.x] = max[0];
}
```

Un peu de pratique avec le TD 9

Objectifs

- Observer l'influence des warps
- Mettre en œuvre un algorithme d'arbre de réduction